

# Modelos sustitutos para la búsqueda de entradas óptimas


Universidad Autónoma de Madrid

Trabajo Fin de Grado

José Ancizar Arbeláez Nieto  
Tutora: Ángela Fernández Pascual  
Grado en Ciencia e Ingeniería de Datos

# Punto de partida: optimizar la selección de nuevas dietas

El Grupo de Ingredientes Alimentarios Saludables de la UAM planteó un problema aplicado en alimentación de larvas *Hermetia Illucens* y *Tenebrio molitor* con las siguientes características:



Objetivo: decidir qué nueva dieta ensayar para obtener larvas que aporten más nutrientes.

# Qué es un modelo sustituto

Un modelo sustituto aprende una aproximación barata de evaluar de una función o sistema costoso  $f(x)$ , para reducir el número de evaluaciones reales necesarias.

## Qué caracteriza al problema

- Caja negra
- Validación experimental costosa
- Datos escasos

## Qué aporta el sustituto


- Consulta rápida
- Optimización Basada en Sustitutos (SBO)
- Criterio de adquisición

Diferencia con ML estándar

No basta con “predecir bien” en promedio: El modelo debe apoyar una decisión bajo presupuesto limitado.

# Del sustituto a la decisión secuencial


Usar el modelo para proponer dónde invertir la siguiente evaluación.



La clave no es explorar todo el espacio, sino elegir mejor el próximo ensayo.

# Del sustituto a la decisión secuencial

Usar el modelo para proponer dónde invertir la siguiente evaluación.




La clave no es explorar todo el espacio, sino elegir mejor el próximo ensayo.

# De pesos inciertos a funciones plausibles

Partimos de una función parametrizada, pero tratamos sus pesos como variables aleatorias.

$$f(x) = \phi(x)^\top \mathbf{w}, \quad \mathbf{w} \sim \mathcal{N}(\mathbf{0}, \Sigma_p)$$

Cada posible  $\mathbf{w}$  induce una función distinta; la incertidumbre sobre los pesos se traduce en incertidumbre sobre la función.




Muestras de funciones inducidas por distintas elecciones de  $\mathbf{w}$

# Del prior sobre pesos a la función de covarianza

El prior sobre los pesos induce una covarianza entre los valores de la función. En GP, esa covarianza se expresa mediante el kernel.

$$\text{Cov}(f(x), f(x')) = \phi(x)^\top \Sigma_p \phi(x') = k(x, x')$$

El kernel  $k(x, x')$  codifica cómo se relacionan los valores  $f(x)$  y  $f(x')$ .




Si  $k(x, x')$  es alto, observar  $f(x)$  informa sobre  $f(x')$

# Proceso Gaussiano: un prior sobre funciones

Antes de observar datos, el GP define una familia de funciones plausibles.

$$f(\cdot) \sim \mathcal{GP}(m(\cdot), k(\cdot, \cdot))$$

Queda especificado por una media  $m(x)$  y un kernel  $k(x, x')$  que define la covarianza entre valores de la función.



media del prior, banda de variabilidad y muestras de las funciones plausibles




# Antes de observar: una gaussiana conjunta

Para predecir en un nuevo punto  $x_*$ , consideramos conjuntamente las salidas en  $X$  y el valor desconocido  $f_*$ .

$$\begin{bmatrix} Y \\ f_* \end{bmatrix} \sim \mathcal{N} \left( \begin{bmatrix} m_X \\ m_* \end{bmatrix}, \begin{bmatrix} K_{XX} + \sigma_n^2 I & k_* \\ k_*^\top & k_{**} \end{bmatrix} \right)$$

Antes de observar los datos, tanto las observaciones de  $Y$  como el valor desconocido  $f_*$  son variables aleatorias y forman una gaussiana conjunta.




Marcas inferiores: entradas  $X$ ; línea discontinua: punto candidato  $x_*$ .

# Datos observados: fijar $Y = y$

Observamos el sistema real en un conjunto finito de entradas  $X$ .

$$\mathbf{y} = (y_1, \dots, y_n)$$

Cada evaluación es costosa: estos puntos son toda la información experimental disponible.




Puntos negros: observaciones disponibles.  
línea discontinua: referencia visual.

# Predicción por condicionamiento gaussiano

Al observar  $y$ , condicionamos la gaussiana conjunta y obtenemos la distribución posterior en  $x^*$ .

$$f^* | X, y, x^* \sim \mathcal{N}(\mu(x^*), \sigma^2(x^*))$$

La posterior favorece las funciones compatibles con los datos observados.



Media posterior, banda de incertidumbre y muestras compatibles con los datos.

# Predicción e incertidumbre posterior


Para cada punto candidato  $x_*$ , el GP devuelve una media  $\mu(x_*)$  y una varianza  $\sigma^2(x_*)$ .

$$\mu(x_*) = m_* + \mathbf{k}_*^\top (K_{XX} + \sigma_n^2 I)^{-1} (\mathbf{y} - \mathbf{m}_X)$$

La media posterior corrige la media previa usando los residuos observados, ponderados por el kernel.

$$\sigma^2(x_*) = k_{**} - \mathbf{k}_*^\top (K_{XX} + \sigma_n^2 I)^{-1} \mathbf{k}_*$$

La varianza baja cuando  $x_*$  está bien explicado por las observaciones y crece en zonas poco cubiertas.



La banda se estrecha donde los datos informan al modelo y se ensancha en regiones menos observadas.

# Kernel: hipótesis de regularidad del GP


Con los mismos datos, cambiar  $k(x, x')$  cambia las funciones que el GP considera plausibles.

$$k(x, x') = \text{Cov}(f(x), f(x'))$$


El kernel define la covarianza entre valores de la función.

La familia de kernel fija qué tipo de comportamiento puede aprender el sustituto.


RBF




Matérn 3/2



Matérn 5/2




Lineal



# Del sustituto a la decisión secuencial


Usar el modelo para proponer dónde invertir la siguiente evaluación.



La clave no es explorar todo el espacio, sino elegir mejor el próximo ensayo.

# Del sustituto a la decisión secuencial

Usar el modelo para proponer dónde invertir la siguiente evaluación.



La clave no es explorar todo el espacio, sino elegir mejor el próximo ensayo.

# El dilema exploración-explotación

El GP aporta una media y una incertidumbre; decidir la siguiente evaluación exige equilibrar ambas.

## EXPLOTACIÓN

$$x_{\text{next}} \approx \arg \min_x \mu(x)$$

Prioriza entradas con mejor media predictiva.


Riesgo: refinar una cuenca local demasiado pronto.

## EXPLORACIÓN

$$x_{\text{next}} \approx \arg \max_x \sigma(x)$$

Prioriza regiones con alta incertidumbre.

Riesgo: evaluar zonas poco prometedoras.



la función real es solo referencia didáctica: el sustituto decide con la media y la incertidumbre



# Expected Improvement: de predicción a decisión

El estima, bajo la posterior actual del GP, cuánto puede mejorar cada candidato respecto al mejor valor observado.

**Incumbent — mejor valor observado hasta ahora**

$$f_{\min} = \min_{i=1, \dots, n} y_i$$

**El candidato aún es incierto: la mejora es aleatoria**

$$I(x) = \max(0, f_{\min} - Y(x))$$

**Expected Improvement — mejora esperada bajo la posterior**


$$EI(x) = (f_{\min} - \mu(x))\Phi(Z) + \sigma(x)\phi(Z)$$

$\Phi$ : CDF normal ·  $\phi$ : densidad normal.

El máximo de El combina una media plausible con incertidumbre; no es simplemente el mínimo de la media predictiva.

**Criterio de infill en SBO**

**Evaluar a continuación el candidato que maximiza EI.**



# Benchmark sintético: validación del ciclo GP + El

El detalle completo se recoge en la memoria; aquí se conserva la lectura necesaria para interpretar el caso real.

① **316 / 372** Trayectorias GP reducen el *incumbent* final.

El ciclo GP + El tiende a encontrar mejores valores con pocas evaluaciones.

② **Dependencia del Problema**

El paisaje objetivo y la dimensión condicionan el ritmo de mejora. La dificultad del Benchmark pesa más que una decisión aislada del pipeline.

③ **Sin configuración universal**

No hay un GP + El óptimo para todos los casos.



# Validación Leave-One-Diet-Out (LODO)


Cada test externo es una dieta completa; los hiperparámetros se seleccionan solo con las dietas restantes.

## Datos agrupados

no filas sueltas

11 dietas × 3 réplicas

Las réplicas de una misma dieta permanecen juntas: o todas en train o todas en test.



¿Por qué no split aleatorio?

● ● ● misma dieta mezclada en train y test

● ● ● LODO retiene la dieta completa

## Proceso LODO anidado

externo + interno

① **Fold externo: reservar una dieta completa como test**

$D_k$  queda fuera hasta el final; no participa ni en el ajuste ni en la selección de hiperparámetros.

$D_k \rightarrow \text{test externo}$

$\mathcal{G} \setminus \{D_k\} \rightarrow \text{train externo}$

② **Fold interno: seleccionar hiperparámetros dentro del train externo**

Se repite LODO solo sobre las dietas restantes; la dieta  $D_k$  no entra en esta selección.

solo con dietas del train externo

$D_\ell \rightarrow \text{validación interna}$

$\{D_j : j \neq k, j \neq \ell\} \rightarrow \text{train interno}$

MAE  
interno

$\rightarrow \theta^*$   
parámetros  
elegidos

③ **Reentrenar y evaluar el fold externo**

Con los parámetros elegidos, el modelo se ajusta con todas las dietas del train externo y se evalúa en  $D_k$ .

train externo +  $\theta^*$

→ modelo del fold

→ predicción sobre  $D_k$

Se repite para  $k = 1, \dots, 11$  y se agregan los errores externos.

LODO mide generalización por dieta: la formulación retenida no interviene ni en el ajuste ni en la selección.